

第12周周报 覃海旭

本周工作主要是对跨域推荐方向相关的近期论文进行阅读与总结。

一、论文阅读

1.A Multi-view Graph Contrastive Learning Framework for Cross-Domain Sequential Recommendation

期刊会议：RecSys2023

方向分类：跨域序列推荐

• 解决的问题：

1. 数据稀疏性：

目标域中项目和用户的交互频次有限，导致推荐效果欠佳。

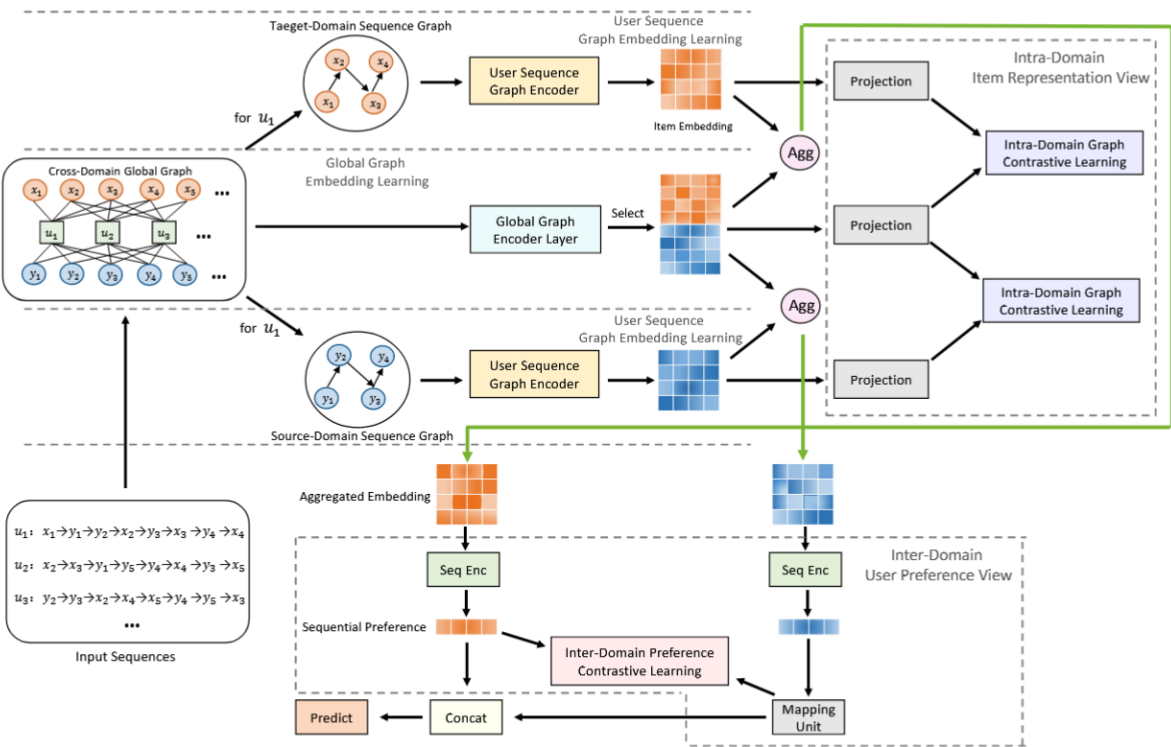
2. 跨域行为序列的关联忽视：

现有方法通常独立捕获每个领域的用户偏好，忽视了不同领域序列之间的项目转换模式，即用户在一个领域的交互可能会影响其在其他领域的下一次交互。

• 创新点：

提出了一个通用的多视图图对比学习框架（MGCL），从域内项目表示视图和域间用户偏好视图两个角度进行问题建模。

- 设计了域内图对比学习，整合用户序列图中的动态信息与跨域全局图中的静态协作信息，缓解数据稀疏问题。
- 引入域间偏好对比学习，实现不同领域用户偏好信息的互补与知识迁移。



• 模型架构：MGCL架构如下：

1. 域内项目表示视图：

- 构建两种图结构：

- **用户序列图**：将源域/目标域中每个用户序列交互建模为一张有向图，node为item，边表示在该序列中的点击转换，用于捕获用户在该域中的行为序列模式。
- **跨域全局图**：把源域和目标域的所有交互构成一张U-I的无向二部图，每个用户节点与其交互过的项目节点相连，用于捕获跨域间协作关系。
- 采用GCN编码每种图中的项目表示，并通过对比学习机制学习自监督信号，增强项目嵌入的区分能力。

2. 域间用户偏好视图：

- 聚合源域与目标域中项目的表示作为最终项目表示，并用transformer编码项目序列得到用户在该域的偏好表示。
- 引入映射模块，将源域偏好映射到目标域，增强跨域知识迁移。
- 通过对比学习机制，捕获用户跨域间偏好信息的互补性。

3. 预测层：

- 拼接目标域和源域的用户偏好表示，生成最终用户偏好向量，用于预测用户在目标域中的下一个可能交互项目。

- **数据集**：Amazon(Movie/CD/Book)

2.Exploring False Hard Negative Sample in Cross-Domain Recommendation

期刊会议：RecSys2023

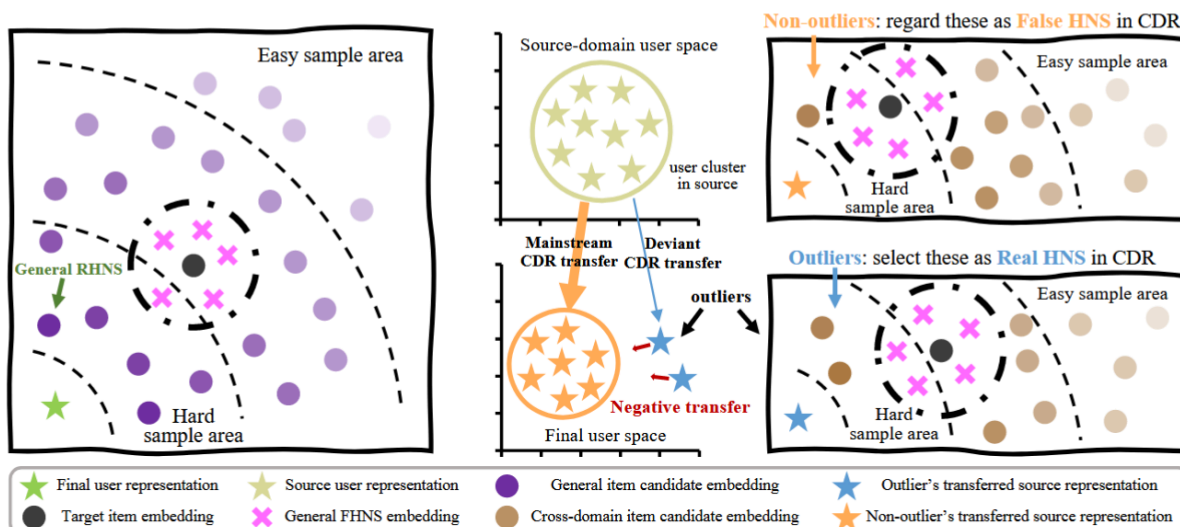
方向分类：跨域序列推荐/负采样优化

• 解决的问题：

常规负采样策略大多选择随机负样本，导致模型训练缺乏挑战性。为此，一些研究提出了难负样本（HNS）的采样方法。然而现有方法在选择HNS时容易包含伪难负样本（FHNS），这些样本实际上是用户有潜在兴趣但未显式交互的项目。这种情况会混淆模型优化，从而降低推荐性能。

• 创新点：

1. 提出假设：与正样本十分接近的项目更可能是伪难负样本(FHNS)，而与正样本**有一定差异**但又具有一定挑战性的项目才是真正的难负样本(RHNS)，并基于该假设设计了通用真实难负样本选择器和跨域真实难负样本选择器。
2. 考虑到**离群点用户**（即在源域和目标域中的偏好差异较大的用户）的存在，并设计相应方法来优化它们的负样本采样策略。
3. 考虑到在训练过程开始时引入所有难负样本可能会导致计算浪费和次优性能（因为在训练早期模型难以准确区分简单的负样本和真实的难负样本），设置了**课程学习任务**来动态调节训练中难负样本的比重。



- **模型架构：** RealHNS框架的具体架构如下：

1. 通用真实难负样本选择器

- **粗粒度选择器：**

- 把用户在源域和目标域的行为序列拼接再过MLP作为该用户的偏好表示。
- 利用评分机制对候选样本进行排序，选出与用户偏好表示相似的前1000个项目作为通用RHNS候选集。

- **细粒度选择器：**

- 通过K-means对项目进行聚类，计算每个候选项目与正样本的相似性。
- 动态设定过滤阈值，从通用RHNS候选集中剔除与正样本过于相似的伪难样本。

2. 跨域真实难负样本选择器

- **跨域粗粒度选择器：**

- 利用源域行为信息，通过K-means生成用户在源域的偏好聚类。
- 根据源域用户聚类和目标域用户表示计算目标域用户质心，再把用户源域表示和目标域用户质心拼接过MLP得到先验源域用户偏好表示。
- 根据先验源域用户偏好表示计算相似的前1000个项目作为跨域RHNS候选集。

- **跨域细粒度选择器：**

- 动态用户过滤：通过距质心距离来识别跨域迁移中偏好的偏移用户（离群点）。
- 动态项目过滤：剔除跨域RHNS候选集中与正样本过于相似的伪难样本。
- 非离群点用户只从通用RHNS跨域候选集中进行采样，而离群点用户同时用通用RHNS候选集和跨域RHNS候选集中进行采样。

3. 课程学习模块

- **优化型课程学习：**

- 动态调整RHNS的采样数量，从简单样本开始，逐步过渡到难负样本。

- **过滤型课程学习：**

- 动态扩大负样本过滤范围，逐步纳入更多高难度的负样本进行训练。

- **数据集：** 在下面2个跨域场景下进行实验：

- Amazon(Toy/Game)
- Amazon(Book/Movie)

3. Towards Universal Cross-Domain Recommendation

期刊会议：WSDM2023

方向分类：多场景跨域推荐

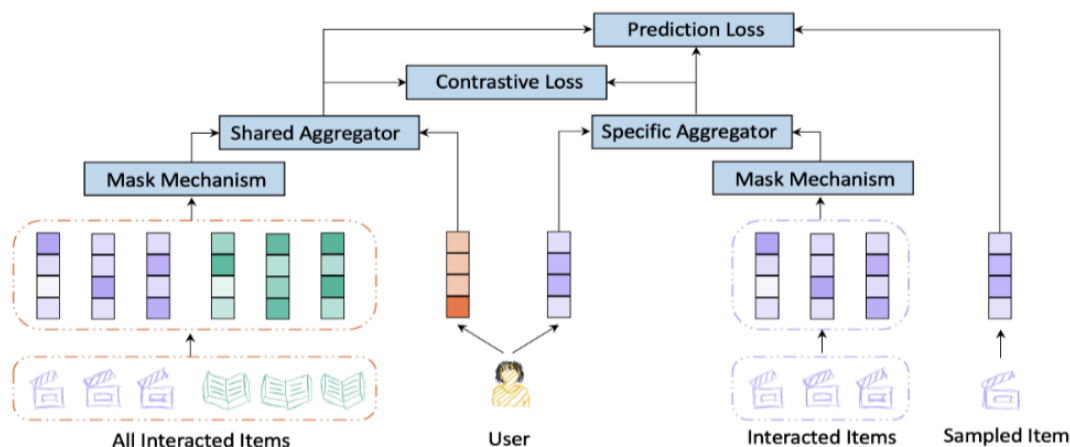
- **解决的问题：** 传统的跨域推荐主要解决两个问题：

- **数据稀疏性：** 利用源域的数据来提高目标域的推荐质量，解决目标域中用户和物品交互数据稀少的问题。(域内推荐)
- **冷启动：** 为目标域没有交互记录的新用户提供推荐，利用其他领域的交互数据进行跨域推荐。(域间推荐)

现有方法往往专注于单一场景，无法同时应对这两类问题。

- **创新点：**

提出了一个名为UniCDR的统一框架，可以处理多种跨域推荐场景，提供一种能够普适于不同需求的解决方案。



- **模型架构：** UniCDR的架构包含以下模块：

1. **嵌入层：**

生成领域特定的用户/物品嵌入以及领域共享用户嵌入，通过查表直接获取嵌入表示。

2. **聚合器架构：**

- 提供三种聚合方法，分别适配不同CDR场景：
 - **均值聚合：** 对交互物品信息平均聚合，适用于简单场景。
 - **用户注意力池化聚合：** 通过注意力机制分配物品权重，适合捕捉用户个性化偏好。
 - **物品相似度池化聚合：** 基于物品相似性矩阵，挖掘潜在相关性，适合物品重叠推荐场景。
- 不同聚合器生成领域特定和领域共享表示。

3. **掩码机制：**

为增强模型的鲁棒性，设计了两种数据增强策略：

- **交互掩码：** 随机删除一部分交互数据，模拟不完整的用户行为。
- **领域掩码：** 屏蔽一个领域的的数据，仅使用另一个领域的的数据作为共享聚合器的输入，提升共享表示的泛化能力。

4. **对比学习：**

使用对比损失优化领域共享表示，鼓励模型捕捉跨领域一致的用户偏好，同时最大化共享表示与领域特定表示之间的信息互补。

- **数据集：** 在下面几个跨域场景下进行实验：

- 场景1（双域内推荐）：
 - Amazon(Sports/Cloth)
 - Amazon(Elec/Phone)
- 场景2（双域间推荐）：
 - Amazon(Sports/Cloth)
 - Amazon(Game/Video)
- 场景3（项目重叠的多域内推荐）：
 - M3Rec提供的五个匿名国家的电子产品交互数据
- 场景4（用户重叠的多域内推荐）：
 - UniCDR构建的一个来自三个在线银行平台的真实金融数据集

4. One for All, All for One: Learning and Transferring User Embeddings for Cross-Domain Recommendation

期刊会议: WSDM2023

方向分类: 多目标跨域推荐 (多域间推荐)

• 解决的问题:

多目标跨域推荐中存在的**数据稀疏性**和**负迁移**问题。现有方法通常仅适用于单目标或双目标的跨域推荐，难以扩展到多目标场景。此外，这些方法常因数据不平衡问题导致负迁移。

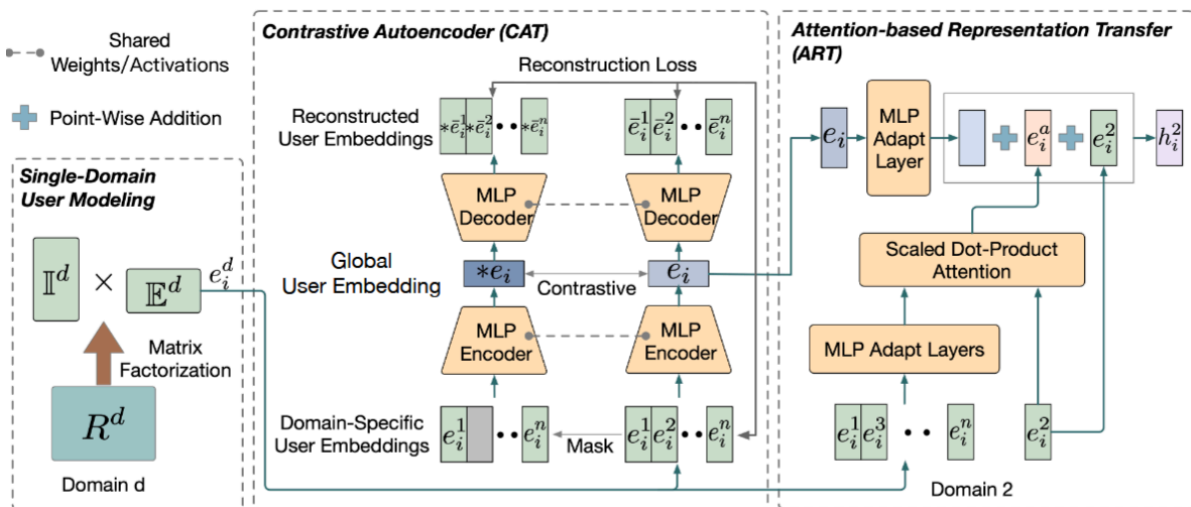
• 创新点:

提出多目标跨域推荐框架CAT-ART，针对2个目标:

1. **全局用户表示 (域共享表示) 提取**: 设计了一个对比自动编码器，通过随机遮盖某些领域的嵌入和对比学习的方式生成通用的全局用户嵌入。

2. **负迁移缓解**:

设计了基于注意力的表示迁移模块，使用注意力机制将其他领域的域特定嵌入整合到目标域。



• 模型架构: CAT-ART的模型架构如下:

1. 对比自动编码器模块

- 输入: 每个用户在不同领域的领域特定嵌入。
- 输出: 全局用户嵌入，代表用户在所有领域中的通用偏好。
- 方法:
 - 通过自动编码器将领域特定嵌入压缩为全局用户嵌入，并通过解码器重建原始输入。
 - 使用对比学习的掩码机制，随机遮盖领域嵌入以模拟缺失信息，提升模型鲁棒性。
 - 损失函数包括重构损失和对比损失，确保全局嵌入具有域不变性和表达能力。

2. 基于注意力的表示迁移模块

- 输入: 目标领域用户嵌入、全局嵌入以及其他领域的迁移嵌入。
- 输出: 增强的目标领域用户嵌入。
- 方法:
 - 通过注意力机制选择性集成相关领域的嵌入，同时弱化不相关或质量低的嵌入。
 - 动态调整迁移嵌入的权重，确保负迁移最小化。
 - 将目标领域嵌入、全局嵌入和迁移嵌入进行融合得到最终的目标域用户嵌入

- 数据集：从腾讯旗下的多个真实应用收集了五个域的用户日志：
 - 应用程序安装偏好(App-Ins)
 - 应用程序使用偏好(App-Use)
 - Articles
 - 短视频(Video-S)
 - 长视频(Video-L)

二、对比总结

对已阅读的跨域推荐相关论文进行对比总结：

对抗训练（GAN）思想的应用：

模型	方法	目的
DiCUR-CDR(第9周第1篇)	生成器生成反馈向量，判别器判别该反馈向量是生成器生成的还是用户真实的反馈	使得生成器生成更加真实的反馈向量作为推荐结果
CDAT(第9周第2篇)	生成器编码源域和目标域的领域不变的用户偏好分布（可以理解为域共享表示），判别器判别该表示来自源域还是目标域	使得生成器编码的用户偏好表示具有领域不变性
C^2DR (第10周第4篇)	生成器编码域特定表示和域共享表示，域分类器用作判别器，判别输入的表示是域共享表示还是域特定表示。引入梯度反转层用于欺骗分类器，使得模型更难以区分域共享信息和域特定信息	使得生成器编码的共享表示真正对所有域都通用，而特定表示仅适用于相应的域
OmniMatch(第11周第2篇)	与 C^2DR 的方式基本相同，同样是采用具有梯度反转层的域分类器进行对抗训练	使用户特征保持领域无关，减少源域和目标域特征分布的差异

域共享表示和域特定表示的解耦：

模型	方法	目的
DiCUR-CDR(第9周第1篇)	判别典型相关分析	在最大化域共享用户表示之间的相关性的同时添加额外的约束来学习域特定表示之间的差异
MITrans(第10周第2篇)	互信息约束	最大化不同域间物品嵌入的相似度以学习共享偏好，最小化域间物品嵌入的依赖关系以保留特定偏好
C^2DR (第10周第4篇)	因果表示解耦	确保域共享表示和域特定表示的向量正交性（余弦相似度最小化）和统计分布独立性（协方差为0）

负迁移问题的优化：

模型	方法	目的
PPA(第9周第5篇)	原型感知学习	通过构建偏好原型以量化用户偏好，从而减少源域冗余特征的影响

模型	方法	目的
CUT(第10周第1篇)	相似性约束	通过限制损失函数让目标域中相似的用户对的嵌入在源域中仍然保持相似
CrossAug(第10周第3篇)	特征交叉重构	通过数据增强的方式来缓解负迁移
C^2DR (第10周第4篇)	正交化约束	强制域共享信息在两个域的损失函数梯度之间保持正交性。确保域特定信息在一个域内仅影响该域的推荐结果，不会对其他域的推荐产生干扰
M2GNN(第11周第4篇)	动态路由网络+自注意力+skip-gram正则化	增强标签语义相关性并去除无关标签，减少噪声对模型的影响
CAT-ART(第12周第4篇)	注意力机制	通过注意力机制选择性集成相关领域的嵌入，同时弱化不相关或质量低的嵌入

无重叠user/item下的跨域推荐：

模型	方法
PrepRec(第9周第4篇)	通过建模物品流行度的变化来学习通用表示
MITrans(第10周第2篇)	通过互信息来学习不同域的共享偏好

特征信息补充/增强样本的生成：

模型	方法
MACD(第11周第1篇)	引入辅助行为序列（如点击）来丰富用户的兴趣信息
OmniMatch(第11周第2篇)	用辅助域相似用户的评论作为目标域冷启动用户的辅助评论
M2GNN(第11周第4篇)	引入标签信息
AutoTransfer(第11周第3篇)	显式选择源域中的实例迁移到目标域
CrossAug(第10周第3篇)	通过特征交叉重构的方式生成域内和跨域增强样本
MITrans(第10周第2篇)	通过预训练语言模型(BERT)，从项目文本数据中提取语义嵌入，用于后续的偏好学习

负采样优化：

模型	方法	目的
SCE(第7周第4篇)[普通序列推荐]	通过分桶计算相似度的方式找到难负样本，避免对所有可能item组合进行计算	减少查找难负样本的计算量

模型	方法	目的
RealHNS(第12周第2篇) [跨域序列推荐]	(1) 引入难负样本和伪难负样本的概念，排除那些与正样本过于相似的伪难负样本 (2) 考虑到跨域推荐场景下的离群点用户，针对它们设计了两个不同的负样本集	找到更高质量的负样本