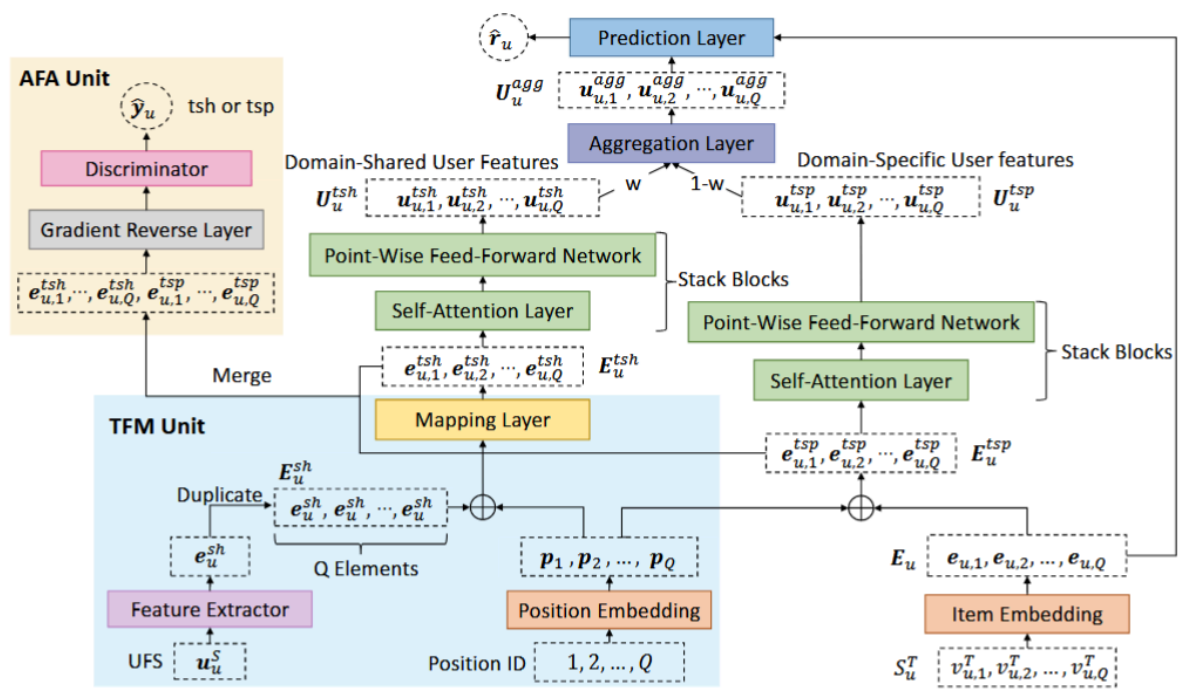


一、论文阅读

1.TPUF: Enhancing Cross-domain Sequential Recommendation via Transferring Pre-trained User Features

期刊会议：WSDM2023  
方向分类：跨域序列推荐

- 解决的问题：  
大多数现有的跨域推荐方法需要直接访问源域和目标域的用户交互数据，但由于隐私保护政策，公司往往不愿共享原始交互数据。
- 创新点：  
设计了一个特征映射与聚合框架，仅通过转移源域的预训练用户特征而非原始交互数据来实现跨域序列推荐。



- 模型架构：TPUF模型架构如下：
  - 时间特征映射单元（TFM）
    - 动机：用户的源域预训练特征不一定编码了序列信息（也就是说用非序列推荐模型进行编码的），作者想让它有时间信息
    - 方法：先把源域用户特征进行映射，再复制Q次（Q为序列长度），来模拟一整个序列。最后再通过一层MLP作为源域用户序列
  - 序列特征编码  
目标域用户序列和位置信息通过SASRec转换为领域特定特征；TFM编码的源域用户序列用同样方式转换为领域共享特征（我感觉称为源域特定特征更为确切，因为没有源域和目标域特征融合的过程）。
  - 对抗特征对齐单元（AFA）  
基于对抗学习，通过梯度反转层和域分类器对齐源域和目标域的特征分布。判别器判别输入用户特征来自源域还是目标域。

#### 4. 聚合和预测

加权聚合领域共享和领域特定特征，生成综合用户特征进行预测。

- 数据集：

- Douban(Movies/Books)
- Amazon(Movies/Books)
- Amazon(Sports/Clothing)

## 2.Sequential Recommendation via an Adaptive Cross-domain Knowledge Decomposition

期刊会议：WSDM2023

方向分类：跨域序列推荐

- 解决的问题：

1. **动态性不足**：现有方法多基于静态迁移，难以捕捉用户的动态偏好。
2. **混杂因素的干扰**：在迁移过程中未充分去除混杂因素，可能引入偏差。
3. **领域差异影响**：不同领域间的属性差异导致直接知识迁移可能产生噪声，影响模型性能。

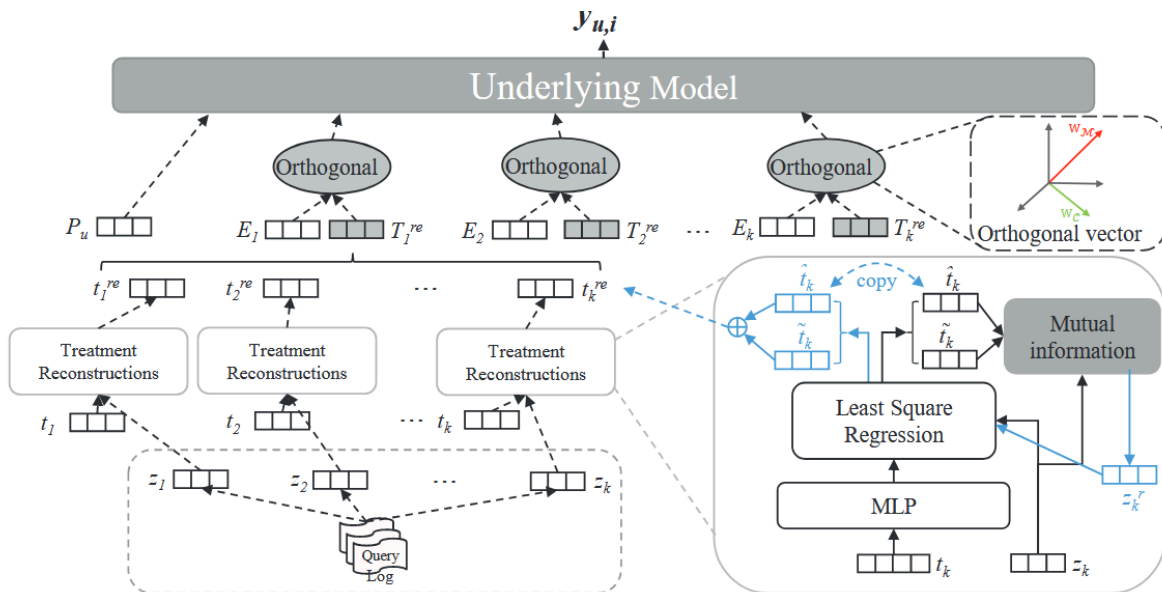
- 创新点：

引入**因果学习**技术，通过因变量来移除混杂因素的影响，在优化过程中动态调整因变量表示，确保其满足相关性和排除性条件。

什么是**因果学习**？

经典的相关性分析是为了发现变量之间的相关性（例如冰淇淋销量与溺水人数之间有很强的正相关），但因果学习的目的是进一步探究这些现象是否存在因果关系（例如，炎热天气可能是它们的共同原因）

因果学习的核心是通过数学模型和算法，去除混杂因素的影响，从而更准确地揭示一个变量（原因）对另一个变量（结果）的真实影响。本文采用的方法是引入一个工具变量(IV)，然后通过两阶段最小二乘法方法拟合工具变量与原因变量，将表示分解为因果关联部分和非因果关联部分，从而对原因变量进行重构，去除混杂因素影响。



- 模型架构：ARISEN框架如下：

1. 变量表示模块：

- 定义原因变量（Treatment）：用户的源域交互行为序列。
- 定义工具变量（IV）：用户的查询行为序列，作为去除混杂因素的关键。

- 使用嵌入方法（如BERT）对源域用户行为和查询内容进行编码。

## 2. 原因变量重构模块：

- 基于2SLS（两阶段最小二乘法）拟合原因变量和工具变量，将原因变量分解为因果关联（拟合部分）和非因果关联（残差部分）。
- 对分解后的嵌入进行加权重构，既保留因果信息，又适当利用非因果信息，提升推荐效果。把重构后的源域表示用于后续跨域特征迁移。

## 3. 正交映射模块：

- 通过正交变换矩阵，分别处理源域和目标域的嵌入表示，并引入正交化约束损失函数，确保源域和目标域表示的差异性，同时增强推荐性能。
- 把源域和目标域的嵌入表示进行融合作为最终表示。

## 4. 工具变量协同优化模块：

- 利用互信息最大化技术优化因变量的相关性（与处理变量的相关性）和排除性（与输出变量的独立性），动态调整IV表示，确保其在整个训练过程中的有效性。

### • 数据集：

- Lenovo工业数据集（未公开）
- Amazon(Book/Movie)

## 3.FedDCSR: Federated Cross-domain Sequential Recommendation via Disentangled Representation Learning

期刊会议：SDM2024

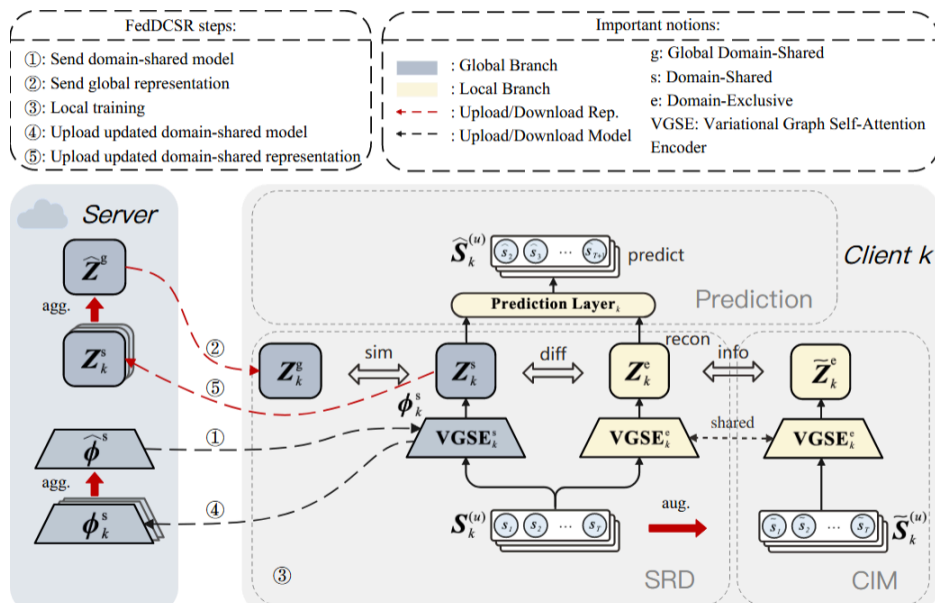
方向分类：联邦跨域序列推荐

### • 解决的问题：

1. 现有的跨领域序列推荐方法通常需要在不同领域间共享用户原始数据，无法保障用户隐私。
2. 不同领域之间的序列特征存在异质性，直接使用联邦学习方法会导致性能下降。

### • 创新点：

1. 针对保护用户隐私的需求，设计联邦跨域序列推荐场景，即用户序列被视为隐私信息，不能直接在领域间共享。本地域之间只传递域共享表示和域共享编码器参数。
2. 基于互信息原理设计了三个不同损失来更好地学习域共享表示和域专属表示。
3. 通过随机打乱序列顺序的方法对用户序列进行数据增强，生成新的训练样本来进行对比学习，从而增强域专属表示中的用户偏好信息。



- **模型架构：** FedDCSR模型架构如下：

#### 1. 变分图自注意力编码器模块(VGSE):

- 通过两个不同GNN处理用户-物品交互图，编码物品的域共享和域专属嵌入。
- 把序列嵌入、序列位置嵌入和物品嵌入（共享的和专属的）分别相加后输入自注意力网络进行编码，得到域共享表示和域专属表示。

#### 2. 域内-域间序列表示分解模块(SRD):

基于互信息原理，设计差异损失、相似性损失和重构损失，分离领域共享与领域专属信息：

- **差异损失：** 使域共享表示与域专属表示的互信息最小化，从而扩大它们的差异。
- **相似性损失：** 使域共享表示与全局表示（域共享表示之和）的互信息最大化，促进领域共享特征与全局特征的一致性。
- **重构损失：** 使域专属表示与对应序列编码的互信息最大化，使领域专属表示能够重构其所在领域的序列数据。

#### 3. 域内对比信息最大化模块(CIM):

- 通过数据增强（序列随机打乱）和对比学习，增强域专属表示中的用户偏好信息。
- 对比学习以原始序列表示和打乱后的同一个序列表示为正样本，以原始序列表示和其它序列表示为负样本。

- **数据集：**

- Amazon(Food-Kitchen-Cloth-Beauty)
- Amazon(Movie-Book-Game)
- Amazon(Sports-Garden-Home)

### 4. Cross-domain recommendation via user interest alignment

期刊会议：WWW2023

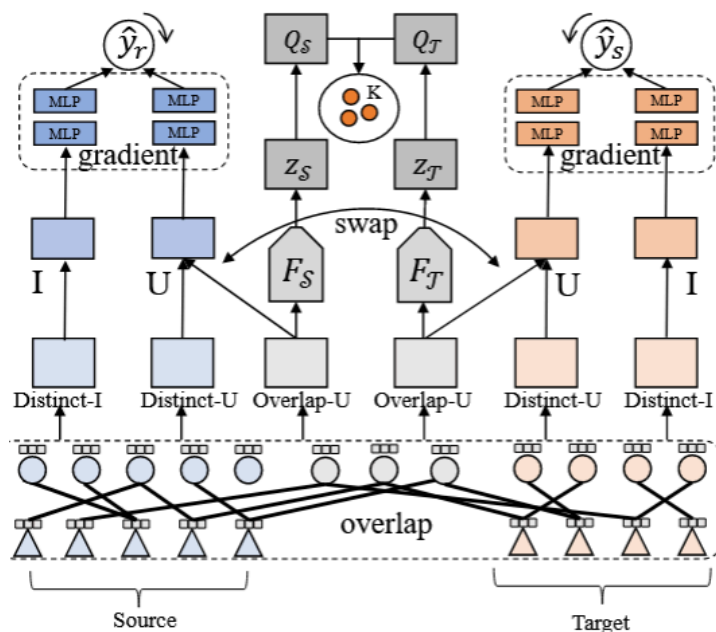
方向分类：跨域推荐

- **解决的问题：**

1. **跨域相似性捕捉不足：** 大多数方法独立训练用户在各领域的嵌入表示，然后以简单的方式进行聚合，导致未能充分捕捉用户和物品的跨域相似性。
2. **用户兴趣一致性问题：** 现有方法通过简单的嵌入合并进行知识转移，缺乏对用户兴趣分布一致性的约束，可能导致不同领域间用户偏好的冲突。
3. **依赖完全重叠用户：** 许多研究假设用户在各领域完全重叠，忽视了实际场景中部分重叠用户的普遍性。

- **创新点：**

1. 构建了一个统一的跨领域异构图，以重叠用户为桥梁将源域与目标域的用户-物品交互图拼接在一起，重新设计图卷积网络的消息传递机制以捕捉高阶相似性。
2. 提出了基于对比学习和梯度对齐的方法，从用户-用户和用户-物品两个角度实现用户兴趣的对齐。



• **模型架构：**COAST模型架构如下：

1. **跨领域异构图构建与传播：**

- 将两个领域的用户和物品交互联合为统一图结构。
- 从内容数据（如评论、标签、用户/物品档案）中提取特征作为节点的初始嵌入表示。
- 通过改进的图卷积网络消息传递规则，利用用户-物品交互信息捕提高阶跨领域相似性。

2. **用户兴趣对齐：**

■ **用户-用户对齐**

- 基于对比学习约束不同视角下的用户兴趣分布一致。
- 聚合用户在源域和目标域的2跳邻接节点信息作为该用户的对比视角。
- 基于同一用户的不同视角的兴趣分布应当一致的假设，通过交叉熵损失度量用户在源域和目标域兴趣分布的一致性。

■ **用户-物品对齐**

- 利用梯度对齐确保用户对已交互物品的偏好在投影空间中保持接近。
- 梯度来源：源域和目标域中U-I评分预测损失的期望。
- 通过最小化源域和目标域中梯度的余弦相似度来约束用户对物品的偏好在两个领域的一致性。

3. 对比学习以原始序列表示和打乱后的同一个序列表示为正样本，以原始序列表示和其它序列表示为负样本。

• **数据集：**

- Lenovo工业数据集（未公开）
- Douban(Movie/Book)
- Douban(Movie/Music)
- Douban(Book/Music)

## 二、对比总结

对已阅读的跨域推荐相关论文进行对比总结（加粗为本周论文）：

对抗训练（GAN）思想的应用：

模型	方法	目的
DiCUR-CDR(第9周第1篇)	生成器生成反馈向量，判别器判别该反馈向量是生成器生成的还是用户真实的反馈	使得生成器生成更加真实的反馈向量作为推荐结果
CDAT(第9周第2篇)	生成器编码源域和目标域的领域不变的用户偏好分布（可以理解为域共享表示），判别器判别该表示来自源域还是目标域	使得生成器编码的用户偏好表示具有领域不变性
$C^2DR$ (第10周第4篇)	生成器编码域特定表示和域共享表示，域分类器用作判别器，判别输入的表示是域共享表示还是域特定表示。引入梯度反转层用于欺骗分类器，使得模型更难以区分域共享信息和域特定信息	使得生成器编码的共享表示真正对所有域都通用，而特定表示仅适用于相应的域
OmniMatch(第11周第2篇)	与 $C^2DR$ 的方式基本相同，同样是采用具有梯度反转层的域分类器进行对抗训练	使用户特征保持领域无关，减少源域和目标域特征分布的差异
TPUF(第13周第1篇)	与上面2个基本相同，同样是采用具有梯度反转层的域分类器进行对抗训练	对齐来自两个领域的特征

域共享表示和域特定表示的解耦：

模型	方法	目的
DiCUR-CDR(第9周第1篇)	判别典型相关分析	在最大化域共享用户表示之间的相关性的同时添加额外的约束来学习域特定表示之间的差异
MITrans(第10周第2篇)	互信息约束	最大化不同域间物品嵌入的相似度以学习共享偏好，最小化域间物品嵌入的依赖关系以保留特定偏好
$C^2DR$ (第10周第4篇)	因果表示解耦	确保域共享表示和域特定表示的向量正交性（余弦相似度最小化）和统计分布独立性（协方差为0）
FedDCSR(第13周第3篇)	互信息约束	(1)使域共享表示与域特定表示的互信息最小化，从而扩大它们的差异。 (2)使域共享表示与全局表示（域共享表示之和）的互信息最大化，促进领域共享特征与全局特征的一致性。 (3)使域特定表示与对应序列编码的互信息最大化，使领域专属表示能够重构其所在领域的序列数据。



负迁移问题的优化：

模型	方法	目的
PPA(第9周第5篇)	原型感知学习	通过构建偏好原型以量化用户偏好，从而减少源域冗余特征的影响
CUT(第10周第1篇)	相似性约束	通过限制损失函数让目标域中相似的用户对的嵌入在源域中仍然保持相似
CrossAug(第10周第3篇)	特征交叉重构	通过数据增强的方式来缓解负迁移
$C^2DR$ (第10周第4篇)	正交化约束	强制域共享信息在两个域的损失函数梯度之间保持正交性。确保域特定信息在一个域内仅影响该域的推荐结果，不会对其他域的推荐产生干扰
M2GNN(第11周第4篇)	动态路由网络+自注意力+skip-gram正则化	增强标签语义相关性并去除无关标签，减少噪声对模型的影响
CAT-ART(第12周第4篇)	注意力机制	通过注意力机制选择性集成相关领域的嵌入，同时弱化不相关或质量低的嵌入

无重叠user/item下的跨域推荐：

模型	方法
PrepRec(第9周第4篇)	通过建模物品流行度的变化来学习通用表示
MITrans(第10周第2篇)	通过互信息来学习不同域的共享偏好

特征信息补充/增强样本的生成：

模型	方法
MACD(第11周第1篇)	引入辅助行为序列（如点击）来丰富用户的兴趣信息
OmniMatch(第11周第2篇)	用辅助域相似用户的评论作为目标域冷启动用户的辅助评论
M2GNN(第11周第4篇)	引入标签信息
AutoTransfer(第11周第3篇)	显式选择源域中的实例迁移到目标域
CrossAug(第10周第3篇)	通过特征交叉重构的方式生成域内和跨域增强样本
MITrans(第10周第2篇)	通过预训练语言模型(BERT)，从项目文本数据中提取语义嵌入，用于后续的偏好学习
ARISEN(第13周第2篇)	引入用户的查询数据作为因果学习的工具变量
FedDCSR(第13周第3篇)	通过随机打乱序列顺序的方法对用户序列进行数据增强，生成新的训练样本

模型	方法
COAST(第13周第4篇)	从内容数据（如评论、标签、用户/物品档案）中提取特征作为图节点的初始嵌入表示

负采样优化：

模型	方法	目的
SCE(第7周第4篇)[普通序列推荐]	通过分桶计算相似度的方式找到难负样本，避免对所有可能item组合进行计算	减少查找难负样本的计算量
RealHNS(第12周第2篇)[跨域序列推荐]	(1) 引入难负样本和伪难负样本的概念，排除那些与正样本过于相似的伪难负样本 (2) 考虑到跨域推荐场景下的离群点用户，针对它们设计了两个不同的负样本集	找到更高质量的负样本

因果推断的使用：

模型	方法	目的
$C^2DR$ (第10周第4篇)	将域共享信息和域特定信息视作因果变量，并设计了因果解耦正则化项，来确保域共享和域特定信息在表示空间中满足因果独立性（即向量正交性和统计分布独立性）	域共享表示和域特定表示的解耦
ARISEN(第13周第2篇)	基于工具变量的因果推断，引入用户查询记录作为工具变量，采用两阶段最小二乘法拟合用户交互（原因变量）与用户查询（工具变量）	将原因变量分解为因果关联（拟合部分）和非因果关联（残差部分），从而去除混杂因素造成的偏差